



Aprendizaje No Supervisado: Reducción de Dimensionalidad (PCA)

De la teoría de la varianza a la compresión de imágenes.



El Mapa del Machine Learning: ¿Dónde encaja PCA?



Definición:


El aprendizaje no supervisado busca patrones no detectados en datos sin etiquetas preexistentes.

El Objetivo:

Simplificar la complejidad de los datos (Reducción) sin perder la esencia de la información.

Dos Estrategias: Selección vs. Extracción

Selección de Características



Elige un subconjunto de las variables originales (ej. SelectKBest, RFE). Descarta datos.

Analogía: Despedir jugadores de un equipo.

Extracción de Características (PCA)



Combina variables correlacionadas para crear *nuevas* variables. Preserva la información.

Analogía: Crear un "súper equipo" con las habilidades de todos.

¿Por qué reducir la dimensionalidad?



Visualización: No podemos ver más allá de 3 dimensiones. PCA proyecta datos complejos en 2D o 3D.



Eficiencia: Menos dimensiones = entrenamiento más rápido y menor costo computacional.



Maldición de la Dimensionalidad: En espacios de alta dimensión, los datos se vuelven dispersos y los modelos pierden precisión.



Primer paso (EDA): El Análisis de Correlación identifica redundancia, pero PCA la resuelve matemáticamente.

Análisis de Componentes Principales (PCA)





Algoritmo que transforma m variables independientes en $p \leq m$ nuevas variables **independientes** (no correlacionadas).

Regla de Oro: El objetivo es explicar la mayor **varianza** posible del conjunto de datos.

La Varianza es Información

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{N}$$

Es una medida de dispersión que representa la variabilidad de una serie de datos respecto a su media.



Baja Varianza = Poca Información.




Alta Varianza = Mucha Información.

Intuición Visual: El Problema de la Tetera



¿Qué ángulo eliges? La mejor vista captura la mayor "dispersión" visual. Eso es PCA.

Intuición Visual: El Problema de la Tetera




¿Qué ángulo eliges? La mejor vista captura la mayor "dispersión" visual. Eso es PCA.

Rotación para Maximizar la Información



1. ****Centrar****: Encontrar la media.
2. ****Rotar****: Alinear el eje más largo con la horizontal.
3. ****PC1****: El eje que captura la mayor extensión (varianza).


El Algoritmo PCA - Paso 1: Estandarización



StandardScaler




$$Z = \frac{x - \mu}{\sigma}$$



¡CRÍTICO! PCA es sensible a la escala. Sin estandarización, la variable con números más grandes dominará el análisis falsamente.


Paso 2 y 3: La Matriz de Covarianza y sus Vectores

Eigenvector 1 (Dirección)




- Matriz de Covarianza: Calcula cómo se mueven las variables juntas.
- Eigenvectors: La dirección del nuevo eje (el ángulo de la cámara).
- Eigenvalues: La cantidad de información en esa dirección.

Paso 4: Selección de Componentes



No nos quedamos con todo. Elegimos los primeros p componentes que expliquen la mayoría de la información (ej. 95%).

Aplicación 1: Dataset de Vinos (Tabular)




Origen: 13 características químicas.

Acción: Reducción a 2 Componentes Principales.

Resultado: Separación visual clara de las 3 clases de vino.


Aplicación 2: Compresión de Imágenes (Digits)

Original (64 dimensiones)



Compresión PCA

Reconstrucción (16 componentes)



Se elimina el ruido, permanece la esencia.

Consideraciones y Limitaciones



Interpretabilidad: Las nuevas variables (PC1, PC2) son abstractas. Perdemos el nombre original (ej. 'Alcohol').



Linealidad: PCA asume relaciones lineales.

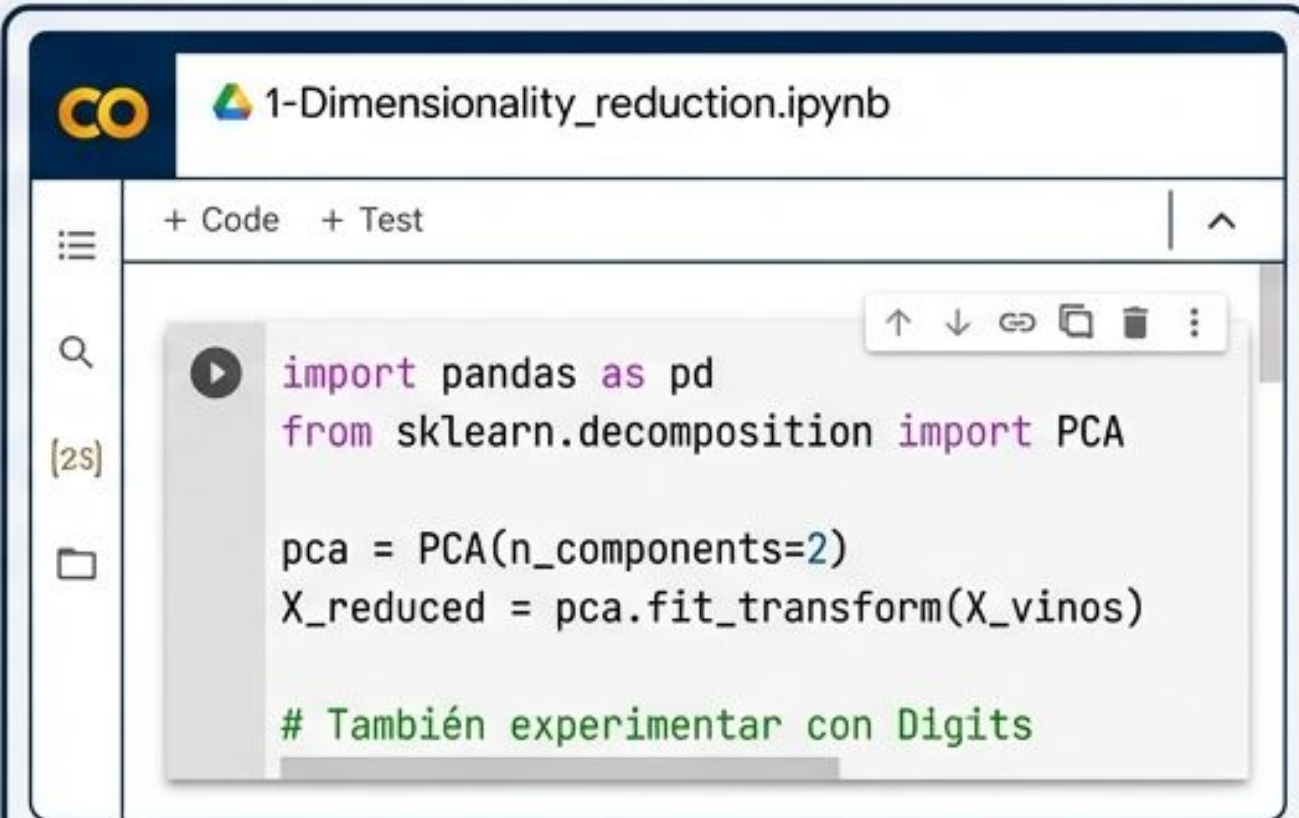


No Linealidad: Para datos como anillos concéntricos, usamos **Kernel PCA (RBF)** para proyectar a dimensiones superiores.

Próximos Pasos: Video y Código



1. Ver Video: 'Presentación tetera PCA' para la intuición.



```
import pandas as pd
from sklearn.decomposition import PCA

pca = PCA(n_components=2)
X_reduced = pca.fit_transform(X_vinos)

# También experimentar con Digits
```

2. Práctica Colab:
'1-Dimensionality_reduction.ipynb'.
Experimentar con Vinos y Digits.

Comparar resultados: Feature Selection vs. PCA.