

TRABAJO UT8

- REDUCCIÓN DE DIMENSIONALIDAD -

Instrucciones:

- Se deberá elaborar un Colab y subir el fichero en el tiempo de entrega establecido
- El fichero deberá nombrarse UT8_nombre_apellido1_apellido2_dni.ipynb
- Se deberá argumentar cada uno de los puntos en el trabajo con una explicación clara
- Se deberá grabar un video de duración máxima de 10 minutos, realizando una breve explicación de cómo se ha abordado cada uno de los puntos.
- El trabajo tendrá una ponderación del 70% y el video con la defensa del 30%. Puntos del trabajo.
- NO se debe usar el mismo DataSet que en los ejemplos de clase. Podéis usar el mismo dataset de la práctica de clasificación.

(1 puntos) Preprocesado de los datos

- Importar dataset
- Manejar datos missing
- Manejar datos categóricos (codificación label, ordinal, one-hot, variables dummies)
- Evitar trampa de las variables dummy
- Separar datos en conjuntos de entrenamiento y test
- Estandarizar o normalizar los datos

(1 punto) Aplicar un modelo de clasificación y evaluar el modelo con una matriz de confusión o una curva ROC.

(1 punto) Correlation Analysis

- Identificar correlaciones haciendo uso de la matriz de correlación, mapas de calor, pair plots
- Justificar aquellas variables de las que podríamos prescindir para mejorar nuestro modelo de machine learning

(1 punto) Features Importances

- Identificar las variables del dataset más importantes utilizando el score de un modelo de árboles de decisión.
- Comparar los resultados obtenidos con el punto anterior.

(1 punto) Univariante selección.

- Utilizar algún método estadístico que permita estudiar la relación de la varianza del conjunto de los datos con la salida (ANOVA)

(1 punto) Recursive Feature Elimination

- Utilizar esta técnica junto con un modelo de clasificación para obtener aquellas características con las que el modelo obtiene mejores resultados.

(1 punto) Eliminar aquellas variables correlacionadas y volver a ejecutar el modelo con el nuevo dataset reducido y comparar resultados con el modelo anterior aplicando una matriz de confusión o una curva ROC.

(1 punto) Aplicar la reducción de dimensionalidad mediante el algoritmo PCA

- Obtener el número de componentes que expliquen el mayor porcentaje de la información.
- Aplicar el algoritmo para reducir la dimensionalidad del problema

(1 punto) Utilizar el modelo de clasificación con el nuevo dataset que contiene las nuevas componentes principales (PCA)

- Evaluar el modelo con una matriz de confusión o una curva ROC y comparar con los resultados anteriores.

(1 punto) Redactar unas conclusiones sobre la comparativa de los resultados de las distintas técnicas de reducción de dimensionalidad aplicadas.