


El Plano del Aprendizaje

Introducción a las Redes Neuronales y el Deep Learning




Entendiendo el ecosistema de la Inteligencia Artificial




Nota clave: ML no es nuevo, pero el DL aplicado de extremo a extremo a conjuntos masivos de datos es la revolución actual.

Machine Learning Tradicional vs. Deep Learning

	Machine Learning Tradicional	Deep Learning
 Volumen de Datos	Funciona bien con datos limitados.	 Requiere conjuntos masivos (ej. ~100,000+ imágenes).
 Dimensionalidad	Ideal para tablas tradicionales (filas y columnas).	 Alta dimensionalidad requerida (ej. imágenes: alto x ancho x 3 canales x 8 bits).
 Proceso de Aprendizaje	Requiere extracción manual de características.	 Aprendizaje de extremo a extremo (End-to-End).
 Complejidad	Rápido, ideal para problemas lineales.	 Computacionalmente costoso (requiere GPUs), ideal para problemas complejos y no lineales.

El origen de la revolución profunda: ImageNet 2012



El Hito



Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton presentaron AlexNet en ILSVRC-2012.

El Logro



Una Red Neuronal Convolutiva Profunda (5 capas convolucionales + 3 totalmente conectadas) que mejoró el margen de error Top-5 en más de un 10%, destrozando a los métodos tradicionales.


Los Ingredientes del Éxito



Uso pionero de la función ReLU, Softmax, Dropout, y el poder de procesamiento paralelo masivo.

Construyendo un modelo desde cero: El mercado inmobiliario en Murcia

Distancia al centro (x_1)	Precio (y)
20m	425.000€
120m	350.000€
670m	245.000€
864m	230.000€



1

El Problema



¿Podemos predecir el precio de una casa (y) basándonos únicamente en su distancia a la Catedral de Murcia (x_1)?

2

El Enfoque

Empezaremos con la estructura de aprendizaje más simple posible y la haremos evolucionar.

El Perceptrón: Aprendiendo a trazar una línea recta



Regresión Lineal Simple

El modelo asigna un "peso" (w_1) a la distancia y un "sesgo" base (b_0).


Fórmula

$$y = x_1 \cdot w_1 + b_0$$

El Límite


Utiliza una función de activación de Identidad. Asume que el mundo es perfectamente recto.

El mundo real no es una línea recta




Una regresión lineal simple falla cuando el patrón de la ciudad cambia drásticamente. Para adaptarnos a las curvas del mundo real, necesitamos capas ocultas y no linealidad.

El salto a la Regresión No Lineal: Capas Ocultas y ReLU



ReLU (Rectified Linear Unit)




Capas Ocultas: Permiten al modelo combinar múltiples transformaciones de los datos.


La Magia de ReLU (2010): Unidad Lineal Rectificada ($f(x) = \max(0, x)$). Permite a la red neuronal 'doblar' la línea y aproximar por tramos cualquier curva compleja en nuestros datos de viviendas.

De predecir precios a clasificar decisiones

The Architecture



The Output



⚙️ Añadiendo Complejidad

Ahora evaluamos Distancia (x_1) y Metros Cuadrados (x_2).

📈 Regresión Logística


En lugar de calcular un precio infinito, usamos funciones como Sigmoid o Softmax en la capa final para comprimir la salida entre 0 y 1.

📊 El Resultado

El modelo traza una "frontera de decisión" para clasificar si una casa es una buena inversión.

Preparando los datos: El taller y la caja fuerte

Train (Entrenamiento)



Los datos que la red observa repetidamente para aprender la relación entre distancia y precio.

Validation (Validación)



Datos usados para ajustar los 'Diales' (Hiperparámetros, como la tasa de aprendizaje o el tamaño del batch), sin que el modelo los memorice.

Test (Prueba)





Datos bajo llave. Solo se usan al final para demostrar que el modelo entiende el mercado y no se ha limitado a memorizar el plano de Murcia.

El motor del aprendizaje: El ciclo de propagación



Pasos 1 y 2: Predicción y Cálculo de Error



Feedforward

Calculamos las salidas pasando los datos a través de las capas usando pesos y sesgos aleatorios iniciales.




La Función de Pérdida

Utilizamos métricas como el Error Cuadrático Medio (MSE).

$$e = (y_{pred} - y_{real})^2$$

Mide exactamente qué tan equivocada está nuestra red. El objetivo de la Inteligencia Artificial es **reducir este número a cero.**

Pasos 3 y 4: Descenso de Gradiente y Backpropagation



La Montaña del Error

El algoritmo está ciego. Solo puede sentir la pendiente del suelo debajo de sus pies calculando derivadas parciales (Gradientes).

Tasa de Aprendizaje (η)


Define el tamaño de los pasos del excursionista.
Paso muy grande: Salta de un lado a otro del valle (falla).
Paso muy pequeño: Tarda una eternidad en llegar al fondo.



Epochs y Batches

Un Epoch se completa cuando el modelo ha iterado (hacia adelante y hacia atrás) sobre todos los ejemplos de entrenamiento de Murcia.

El límite físico: El desvanecimiento del gradiente




El Problema (Vanishing Gradient)

En redes muy profundas, la señal de error se propaga hacia atrás multiplicándose por pesos pequeños.

El Efecto

El gradiente disminuye exponencialmente. Las últimas capas aprenden rápidamente, pero las primeras capas (los cimientos de la red) se quedan estancadas y apenas se actualizan. La red deja de aprender.

Restaurando la señal: ReLU y Normalización




La Solución:

1. Función de Activación ReLU: A diferencia de Sigmoid que comprime los valores, ReLU actúa como un conducto despejado para los valores positivos, permitiendo que el gradiente fluya sin encogerse.

2. Normalización: Estandarizar los datos de entrada (asegurar que la Distancia en metros y el Precio en cientos de miles estén en una escala similar) estabiliza la montaña topográfica del descenso de gradiente.

Escalando a la realidad: El plano completo



De 1 a 100 Características

En el mundo real, no solo miramos la distancia. Miramos metros cuadrados (x_2), habitaciones (x_3), baños (x_4), e incluso hasta 100 variables distintas.



Datos Masivos

Escalamos de 14 casas a un conjunto de datos de 10,000+ propiedades.

El Poder del Deep Learning

Es aquí, con alta dimensionalidad y datos masivos, donde las redes profundas superan cualquier algoritmo tradicional, encontrando patrones invisibles.

La Arquitectura Desmitificada



- **No es magia, es geometría:** Las redes neuronales son estructuras matemáticas diseñadas para aproximar cualquier curva compleja de la realidad.
- **El motor es iterativo:** A través del Feedforward, el cálculo del error y el Backpropagation, la red se esculpe a sí misma paso a paso.
- **El diseño importa:** Funciones como ReLU y una correcta división de datos (Train/Val/Test) evitan el colapso del aprendizaje.
- **Punto Final: Hemos construido el plano. Ahora entendemos cómo aprenden las máquinas.**