

02__primeros_pasos__hdfs_executed

March 11, 2026

0.0.1 Ejercicios prácticos: Operaciones básicas en HDFS

Todos los ejercicios se deben ejecutar como usuario `root` en el contenedor del NameNode. Para cambiar al usuario `root`, ejecuta:

```
# No need to switch user, running as root
```

Ejercicio 1: Exploración de directorios Explora la estructura de directorios en HDFS usando los siguientes comandos:

```
# Listar el contenido del directorio home de root  
hdfs dfs -ls
```

```
# Listar el contenido del directorio raíz /  
hdfs dfs -ls /
```

```
# Listar el contenido del directorio /tmp  
hdfs dfs -ls /tmp
```

```
# Listar directorios con información detallada (tamaño, permisos, etc.)  
hdfs dfs -ls -h /user
```

Ejercicio 2: Crear directorios Crea una estructura de directorios en HDFS bajo tu directorio `home`:

```
# Crear un directorio llamado "datos"  
hdfs dfs -mkdir datos
```

```
# Crear un subdirectorio "datos/entrada" (requiere que "datos" exista)  
hdfs dfs -mkdir datos/entrada
```

```
# Crear múltiples directorios de una vez con -p (crea padres si no existen)  
hdfs dfs -mkdir -p datos/procesados/resultados
```

```
# Verificar que se han creado correctamente  
hdfs dfs -ls -R datos
```

Ejercicio 3: Crear archivos de prueba Crea algunos archivos de texto para practicar:

```

# Crear un archivo local de prueba
echo "Este es el contenido del archivo 1" > /tmp/archivo1.txt
echo "Contenido del archivo número 2" > /tmp/archivo2.txt

# Copiar archivos locales a HDFS
hdfs dfs -put /tmp/archivo1.txt datos/entrada/
hdfs dfs -put /tmp/archivo2.txt datos/entrada/

# Crear un archivo directamente en HDFS usando echo (a través de una tubería)
echo "Archivo creado directamente en HDFS" | hdfs dfs -put - datos/archivo_directo.txt

# Verificar los archivos creados
hdfs dfs -ls datos/entrada/
hdfs dfs -ls datos/

```

Ejercicio 4: Ver el contenido de archivos Lee el contenido de los archivos que has creado:

```

# Ver el contenido de un archivo (similar a cat en el sistema local)
hdfs dfs -cat datos/entrada/archivo1.txt

# Ver el contenido de múltiples archivos
hdfs dfs -cat datos/entrada/archivo1.txt datos/entrada/archivo2.txt

# Ver el contenido con más detalle (muestra también el número de líneas)
hdfs dfs -cat datos/archivo_directo.txt | wc -l

# Ver solo las primeras líneas de un archivo
hdfs dfs -cat datos/entrada/archivo1.txt | head -n 5

```

Ejercicio 5: Copiar y mover archivos Practica copiando y moviendo archivos dentro de HDFS:

```

# Copiar un archivo a otra ubicación
hdfs dfs -cp datos/entrada/archivo1.txt datos/copia_archivo1.txt

# Mover un archivo a otro directorio
hdfs dfs -mv datos/copia_archivo1.txt datos/procesados/

# Verificar que el archivo se ha movido
hdfs dfs -ls datos/procesados/
hdfs dfs -ls datos/entrada/

```

Ejercicio 6: Información sobre archivos y directorios Obtén información detallada sobre archivos y directorios:

```

# Ver el tamaño total de un directorio
hdfs dfs -du -h datos/

# Ver el tamaño de cada archivo dentro de un directorio

```

```
hdfs dfs -du -h -v datos/entrada/
```

```
# Contar el número de archivos en un directorio
```

```
hdfs dfs -ls -R datos/ | grep "^-" | wc -l
```

```
# Ver información detallada de un archivo específico
```

```
hdfs dfs -ls -l datos/entrada/archivo1.txt
```

```
# Ver el espacio total usado y disponible en HDFS
```

```
hdfs dfsadmin -report | grep "Configured Capacity\|DFS Used\|DFS Remaining"
```

Ejercicio 7: Cambiar permisos y propietarios Trabaja con permisos de archivos en HDFS:

```
# Cambiar permisos de un archivo (modo octal)
```

```
hdfs dfs -chmod 644 datos/entrada/archivo1.txt
```

```
# Ver los permisos actuales
```

```
hdfs dfs -ls -l datos/entrada/
```

```
# Cambiar permisos de un directorio y su contenido recursivamente
```

```
hdfs dfs -chmod -R 755 datos/
```

```
# Cambiar el propietario de un archivo (requiere permisos de admin)
```

```
# hdfs dfs -chown root:root datos/entrada/archivo1.txt
```

Ejercicio 8: Comparar archivos locales y en HDFS Compara un archivo local con uno en HDFS:

```
# Ver el contenido del archivo local
```

```
cat /tmp/archivo1.txt
```

```
# Ver el contenido del archivo en HDFS
```

```
hdfs dfs -cat datos/entrada/archivo1.txt
```

```
# Descargar un archivo de HDFS al sistema local
```

```
hdfs dfs -get datos/entrada/archivo1.txt /tmp/descargado.txt
```

```
# Comparar los dos archivos
```

```
diff /tmp/archivo1.txt /tmp/descargado.txt
```

Ejercicio 9: Eliminar archivos y directorios Practica eliminando archivos y directorios:

```
# Eliminar un archivo específico
```

```
hdfs dfs -rm datos/archivo_directo.txt
```

```
# Verificar que se ha eliminado
```

```
hdfs dfs -ls datos/
```

```
# Eliminar un directorio vacío
```

```
hdfs dfs -rmdir datos/procesados/resultados

# Eliminar un directorio con contenido (requiere -r para recursivo)
hdfs dfs -rm -r datos/procesados/

# Eliminar múltiples archivos
hdfs dfs -rm datos/entrada/archivo1.txt datos/entrada/archivo2.txt

# Verificar el estado final
hdfs dfs -ls -R datos/
```

Ejercicio 10: Limpieza final Limpia toda la estructura de directorios y archivos que creaste:

```
# Eliminar el directorio raíz con todo su contenido
hdfs dfs -rm -r datos/

# Verificar que se ha eliminado
hdfs dfs -ls

# Confirmación: el directorio home debe estar vacío (o solo contener "libros" si lo cargaste)
```

```
[1]: # Listar el contenido del directorio home de root
!hdfs dfs -ls

# Listar el contenido del directorio raíz /
!hdfs dfs -ls /

# Listar el contenido del directorio /tmp
!hdfs dfs -ls /tmp

# Listar directorios con información detallada (tamaño, permisos, etc.)
!hdfs dfs -ls -lh /user
```

```
Found 1 items
drwxr-xr-x  - root supergroup          0 2026-03-11 09:42 libros
Found 2 items
drwxr-xr-x  - jovyan supergroup        0 2026-02-26 18:49 /data
drwxr-xr-x  - jovyan supergroup        0 2026-03-11 09:38 /user
ls: `/tmp': No such file or directory
Found 4 items
drwxr-xr-x  - jovyan supergroup        0 2026-02-26 19:15 /user/alumnos
drwxr-xr-x  - root supergroup          0 2026-03-11 09:17 /user/hadoop
drwxr-xr-x  - jovyan supergroup        0 2026-03-11 09:30 /user/jovyan
drwxr-xr-x  - root supergroup          0 2026-03-11 09:43 /user/root
```

```
[2]: # Crear un directorio llamado "datos"
!hdfs dfs -mkdir datos
```

```
# Crear un subdirectorio "datos/entrada" (requiere que "datos" exista)
!hdfs dfs -mkdir datos/entrada

# Crear múltiples directorios de una vez con -p (crea padres si no existen)
!hdfs dfs -mkdir -p datos/procesados/resultados

# Verificar que se han creado correctamente
!hdfs dfs -ls -R datos
```

```
drwxr-xr-x   - root supergroup          0 2026-03-11 10:19 datos/entrada
drwxr-xr-x   - root supergroup          0 2026-03-11 10:19 datos/procesados
drwxr-xr-x   - root supergroup          0 2026-03-11 10:19
datos/procesados/resultados
```

```
[3]: # Usar en terminal - Puede dar problemas o bloquearse en Jupyter
# Crear un archivo local de prueba
# !echo "Este es el contenido del archivo 1" > /tmp/archivo1.txt
!echo "Contenido del archivo número 2" > /tmp/archivo2.txt

# Copiar archivos locales a HDFS
# !hdfs dfs -put /tmp/archivo1.txt datos/entrada/
# !hdfs dfs -put /tmp/archivo2.txt datos/entrada/

# CREAMOS DIRECTAMENTE EN HDFS LO ANTERIOR
!echo "Este es el contenido del archivo 1" | hdfs dfs -put - datos/entrada/
↪archivo1.txt
!echo "Contenido del archivo numero 2" | hdfs dfs -put - datos/entrada/archivo2.
↪txt

# Crear un archivo directamente en HDFS usando echo (a través de una tubería)
!echo "Archivo creado directamente en HDFS" | hdfs dfs -put - datos/
↪archivo_directo.txt

# Verificar los archivos creados
!hdfs dfs -ls datos/entrada/
!hdfs dfs -ls datos/
```

```
Found 2 items
-rw-r--r--   2 root supergroup          35 2026-03-11 10:19
datos/entrada/archivo1.txt
-rw-r--r--   2 root supergroup          31 2026-03-11 10:20
datos/entrada/archivo2.txt
Found 3 items
-rw-r--r--   2 root supergroup          36 2026-03-11 10:20
datos/archivo_directo.txt
drwxr-xr-x   - root supergroup          0 2026-03-11 10:20 datos/entrada
drwxr-xr-x   - root supergroup          0 2026-03-11 10:19 datos/procesados
```

```
[4]: # COMPROBACION DE CODIFICACIÓN
# import unicodedata as ud

# s = "Contenido del archivo número 2" # <- pega aquí la versión que te falla
# [(c, hex(ord(c)), ud.name(c, "?")) for c in s]
```

```
[5]: # COMPROBACION DE CODIFICACIÓN
# !locale
# !python -c "import locale, sys; print('preferred:', locale.
↳ getpreferredencoding(False)); print('fs:', sys.getfilesystemencoding())"
# !echo $LANG ; echo $LC_ALL
```

```
[6]: # Ver el contenido de un archivo (similar a cat en el sistema local)
!hdfs dfs -cat datos/entrada/archivo1.txt

# Ver el contenido de múltiples archivos
!hdfs dfs -cat datos/entrada/archivo1.txt datos/entrada/archivo2.txt

# Ver el contenido con más detalle (muestra también el número de líneas)
!hdfs dfs -cat datos/archivo_directo.txt | wc -l

# Ver solo las primeras líneas de un archivo
!hdfs dfs -cat datos/entrada/archivo1.txt | head -n 5
```

```
Este es el contenido del archivo 1
Este es el contenido del archivo 1
Contenido del archivo numero 2
1
Este es el contenido del archivo 1
```

```
[7]: # Copiar un archivo a otra ubicación
!hdfs dfs -cp datos/entrada/archivo1.txt datos/copia_archivo1.txt

# Mover un archivo a otro directorio
!hdfs dfs -mv datos/copia_archivo1.txt datos/procesados/

# Verificar que el archivo se ha movido
!hdfs dfs -ls datos/procesados/
!hdfs dfs -ls datos/entrada/
```

```
Found 2 items
-rw-r--r--  2 root supergroup          35 2026-03-11 10:20
datos/procesados/copia_archivo1.txt
drwxr-xr-x  - root supergroup           0 2026-03-11 10:19
datos/procesados/resultados
Found 2 items
-rw-r--r--  2 root supergroup          35 2026-03-11 10:19
```

```

datos/entrada/archivo1.txt
-rw-r--r--  2 root supergroup          31 2026-03-11 10:20
datos/entrada/archivo2.txt

```

```

[8]: # Ver el tamaño total de un directorio
!hdfs dfs -du -h datos/

# Ver el tamaño de cada archivo dentro de un directorio
!hdfs dfs -du -h -v datos/entrada/

# Contar el número de archivos en un directorio
!hdfs dfs -ls -R datos/ | grep "^-" | wc -l

# Ver información detallada de un archivo específico
!hdfs dfs -ls -l datos/entrada/archivo1.txt

# Ver el espacio total usado y disponible en HDFS
!hdfs dfsadmin -report | grep "Configured Capacity\|DFS Used\|DFS Remaining"

```

```

36  72  datos/archivo_directo.txt
66 132 datos/entrada
35  70  datos/procesados
SIZE  DISK_SPACE_CONSUMED_WITH_ALL_REPLICAS  FULL_PATH_NAME
35    70                                     datos/entrada/archivo1.txt
31    62                                     datos/entrada/archivo2.txt
4
-ls: Illegal option -l
Usage: hadoop fs [generic options]
    [-appendToFile [-n] <localsrc> ... <dst>]
    [-cat [-ignoreCrc] <src> ...]
    [-checksum [-v] <src> ...]
    [-chgrp [-R] GROUP PATH...]
    [-chmod [-R] <MODE[,MODE]... | OCTALMODE> PATH...]
    [-chown [-R] [OWNER][:[GROUP]] PATH...]
    [-concat <target path> <src path> <src path> ...]
    [-copyFromLocal [-f] [-p] [-l] [-d] [-t <thread count>] [-q <thread pool
queue size>] <localsrc> ... <dst>]
    [-copyToLocal [-f] [-p] [-crc] [-ignoreCrc] [-t <thread count>] [-q
<thread pool queue size>] <src> ... <localdst>]
    [-count [-q] [-h] [-v] [-t [<storage type>]] [-u] [-x] [-e] [-s] <path>
...]
    [-cp [-f] [-p | -p[topax]] [-d] [-t <thread count>] [-q <thread pool
queue size>] <src> ... <dst>]
    [-createSnapshot <snapshotDir> [<snapshotName>]]
    [-deleteSnapshot <snapshotDir> <snapshotName>]
    [-df [-h] [<path> ...]]
    [-du [-s] [-h] [-v] [-x] <path> ...]
    [-expunge [-immediate] [-fs <path>]]

```

```

    [-find <path> ... <expression> ...]
    [-get [-f] [-p] [-crc] [-ignoreCrc] [-t <thread count>] [-q <thread pool
queue size>] <src> ... <localdst>]
    [-getfacl [-R] <path>]
    [-getfattr [-R] {-n name | -d} [-e en] <path>]
    [-getmerge [-nl] [-skip-empty-file] <src> <localdst>]
    [-head <file>]
    [-help [cmd ...]]
    [-ls [-C] [-d] [-h] [-q] [-R] [-t] [-S] [-r] [-u] [-e] [<path> ...]]
    [-mkdir [-p] <path> ...]
    [-moveFromLocal [-f] [-p] [-l] [-d] <localsrc> ... <dst>]
    [-moveToLocal <src> <localdst>]
    [-mv <src> ... <dst>]
    [-put [-f] [-p] [-l] [-d] [-t <thread count>] [-q <thread pool queue
size>] <localsrc> ... <dst>]
    [-renameSnapshot <snapshotDir> <oldName> <newName>]
    [-rm [-f] [-r|-R] [-skipTrash] [-safely] <src> ...]
    [-rmdir [--ignore-fail-on-non-empty] <dir> ...]
    [-setfacl [-R] [{-b|-k} {-m|-x <acl_spec>} <path>]|[--set <acl_spec>
<path>]]
    [-setfattr {-n name [-v value] | -x name} <path>]
    [-setrep [-R] [-w] <rep> <path> ...]
    [-stat [format] <path> ...]
    [-tail [-f] [-s <sleep interval>] <file>]
    [-test -[defswrz] <path>]
    [-text [-ignoreCrc] <src> ...]
    [-touch [-a] [-m] [-t TIMESTAMP (yyyyMMdd:HHmmss) ] [-c] <path> ...]
    [-touchz <path> ...]
    [-truncate [-w] <length> <path> ...]
    [-usage [cmd ...]]

```

Generic options supported are:

```

-conf <configuration file>          specify an application configuration file
-D <property=value>                 define a value for a given property
-fs <file:///|hdfs://namenode:port> specify default filesystem URL to use,
overrides 'fs.defaultFS' property from configurations.
-jt <local|resourcemanager:port>    specify a ResourceManager
-files <file1,...>                  specify a comma-separated list of files to be
copied to the map reduce cluster
-libjars <jar1,...>                 specify a comma-separated list of jar files to
be included in the classpath
-archives <archive1,...>            specify a comma-separated list of archives to
be unarchived on the compute machines

```

The general command line syntax is:

```
command [genericOptions] [commandOptions]
```

```
Usage: hadoop fs [generic options] -ls [-C] [-d] [-h] [-q] [-R] [-t] [-S] [-r]
```



```

[-u] [-e] [<path> ...]
Configured Capacity: 2162202353664 (1.97 TB)
DFS Remaining: 1906634366976 (1.73 TB)
DFS Used: 33010307434 (30.74 GB)
DFS Used%: 1.70%
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 16505180341 (15.37 GB)
Non DFS Used: 56286457675 (52.42 GB)
DFS Remaining: 953317183488 (887.85 GB)
DFS Used%: 1.53%
DFS Remaining%: 88.18%
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 16505127093 (15.37 GB)
Non DFS Used: 56286510923 (52.42 GB)
DFS Remaining: 953317183488 (887.85 GB)
DFS Used%: 1.53%
DFS Remaining%: 88.18%

```

```

[9]: # Cambiar permisos de un archivo (modo octal)
!hdfs dfs -chmod 644 datos/entrada/archivo1.txt

# Ver los permisos actuales
!hdfs dfs -ls datos/entrada/

# Cambiar permisos de un directorio y su contenido recursivamente
!hdfs dfs -chmod -R 755 datos/

# Cambiar el propietario de un archivo (requiere permisos de admin)
# hdfs dfs -chown root:root datos/entrada/archivo1.txt

```

```

Found 2 items
-rw-r--r--    2 root supergroup          35 2026-03-11 10:19
datos/entrada/archivo1.txt
-rw-r--r--    2 root supergroup          31 2026-03-11 10:20
datos/entrada/archivo2.txt

```

```

[10]: # Ver el contenido del archivo local
!cat /tmp/archivo1.txt

# Ver el contenido del archivo en HDFS
!hdfs dfs -cat datos/entrada/archivo1.txt

# Descargar un archivo de HDFS al sistema local
!hdfs dfs -get datos/entrada/archivo1.txt /tmp/descargado.txt

# Comparar los dos archivos
!diff /tmp/archivo1.txt /tmp/descargado.txt

```

```
cat: /tmp/archivo1.txt: No such file or directory
Este es el contenido del archivo 1
get: `/tmp/descargado.txt': File exists
diff: /tmp/archivo1.txt: No such file or directory
```

```
[11]: # Eliminar un archivo específico
!hdfs dfs -rm datos/archivo_directo.txt

# Verificar que se ha eliminado
!hdfs dfs -ls datos/

# Eliminar un directorio vacío
!hdfs dfs -rmdir datos/procesados/resultados

# Eliminar un directorio con contenido (requiere -r para recursivo)
!hdfs dfs -rm -r datos/procesados/

# Eliminar múltiples archivos
!hdfs dfs -rm datos/entrada/archivo1.txt datos/entrada/archivo2.txt

# Verificar el estado final
!hdfs dfs -ls -R datos/
```

```
Deleted datos/archivo_directo.txt
Found 2 items
drwxr-xr-x   - root supergroup          0 2026-03-11 10:20 datos/entrada
drwxr-xr-x   - root supergroup          0 2026-03-11 10:20 datos/procesados
Deleted datos/procesados
Deleted datos/entrada/archivo1.txt
Deleted datos/entrada/archivo2.txt
drwxr-xr-x   - root supergroup          0 2026-03-11 10:22 datos/entrada
```

```
[12]: # Eliminar el directorio raíz con todo su contenido
!hdfs dfs -rm -r datos/

# Verificar que se ha eliminado
!hdfs dfs -ls

# Confirmación: el directorio home debe estar vacío (o solo contener "libros"
↳ si lo cargaste)
```

```
Deleted datos
Found 1 items
drwxr-xr-x   - root supergroup          0 2026-03-11 09:42 libros
```

0.0.2 Prueba de acceso a HDFS y carga de datos

1. En el Namenode, conviértete en usuario no privilegiado (haciendo, como root, `# No need to switch user, running as root`)
2. Comprueba que puedes acceder al HDFS ejecutando:

```
hdfs dfs -ls
```

(Este comando no debería dar ninguna salida, ya que no tenemos nada en ese directorio).

3. Descarga de <https://github.com/dsevilla/bd2-data/releases/download/libros-tar-gz/libros.tar.gz> y descomprime los ficheros de ejemplo usando:

```
wget https://github.com/dsevilla/bd2-data/releases/download/libros-tar-gz/libros.tar.gz -q0 - \
| tar -xzf - -C /tmp
```

4. Siguiendo en el NameNode como usuario root, copia los datos a HDFS:

```
cd /tmp
hdfs dfs -put libros .
hdfs dfs -ls libros
```

Una vez copiados borra el directorio libros del disco local (`rm -rf /tmp/libros*`).

5. Mira en el interfaz web del HDFS dónde se encuentran los bloques correspondientes al fichero **random_words.txt.bz2**. Comprueba que cada bloque tiene 2 réplicas.
 - Abre el navegador y conéctate al interfaz web del NameNode.
 - Ve al menú “Utilities” -> “Browse the filesystem”.

```
[13]: !hdfs dfs -ls
```

```
Found 1 items
drwxr-xr-x  - root supergroup          0 2026-03-11 09:42 libros
```

```
[14]: !wget https://github.com/dsevilla/bd2-data/releases/download/libros-tar-gz/
↳ libros.tar.gz -q0 -
! | tar -xzf - -C /tmp
```

```
libros/
libros/pg17013.txt.gz
libros/pg16625.txt.gz
libros/pg25807.txt.gz
libros/pg32315.txt.gz
libros/random_words.txt.bz2
libros/pg1619.txt.gz
libros/pg7109.txt.gz
libros/pg2000.txt.gz
libros/pg14329.txt.gz
libros/pg24536.txt.gz
libros/pg25640.txt.gz
libros/pg8870.txt.gz
libros/pg18005.txt.gz
```

```
libros/pg5201.txt.gz
libros/pg9980.txt.gz
libros/pg17073.txt.gz
```

```
[15]: %cd /tmp
!hdfs dfs -put libros .
!hdfs dfs -ls libros
```

```
/tmp
put: `libros/pg2000.txt.gz': File exists
put: `libros/pg1619.txt.gz': File exists
put: `libros/pg14329.txt.gz': File exists
put: `libros/pg9980.txt.gz': File exists
put: `libros/pg7109.txt.gz': File exists
put: `libros/random_words.txt.bz2': File exists
put: `libros/pg17013.txt.gz': File exists
put: `libros/pg8870.txt.gz': File exists
put: `libros/pg25640.txt.gz': File exists
put: `libros/pg16625.txt.gz': File exists
put: `libros/pg18005.txt.gz': File exists
put: `libros/pg32315.txt.gz': File exists
put: `libros/pg5201.txt.gz': File exists
put: `libros/pg24536.txt.gz': File exists
put: `libros/pg25807.txt.gz': File exists
put: `libros/pg17073.txt.gz': File exists
Found 16 items
-rw-r--r--  2 root supergroup      441804 2026-03-11 09:41 libros/pg14329.txt.gz
-rw-r--r--  2 root supergroup      264123 2026-03-11 09:41 libros/pg1619.txt.gz
-rw-r--r--  2 root supergroup      455129 2026-03-11 09:42 libros/pg16625.txt.gz
-rw-r--r--  2 root supergroup      939502 2026-03-11 09:42 libros/pg17013.txt.gz
-rw-r--r--  2 root supergroup      737367 2026-03-11 09:42 libros/pg17073.txt.gz
-rw-r--r--  2 root supergroup      219304 2026-03-11 09:42 libros/pg18005.txt.gz
-rw-r--r--  2 root supergroup      813698 2026-03-11 09:41 libros/pg2000.txt.gz
-rw-r--r--  2 root supergroup      328494 2026-03-11 09:42 libros/pg24536.txt.gz
-rw-r--r--  2 root supergroup      504188 2026-03-11 09:42 libros/pg25640.txt.gz
-rw-r--r--  2 root supergroup       38194 2026-03-11 09:42 libros/pg25807.txt.gz
-rw-r--r--  2 root supergroup      103986 2026-03-11 09:42 libros/pg32315.txt.gz
-rw-r--r--  2 root supergroup      125693 2026-03-11 09:42 libros/pg5201.txt.gz
-rw-r--r--  2 root supergroup       82099 2026-03-11 09:41 libros/pg7109.txt.gz
-rw-r--r--  2 root supergroup       99685 2026-03-11 09:42 libros/pg8870.txt.gz
-rw-r--r--  2 root supergroup       85187 2026-03-11 09:41 libros/pg9980.txt.gz
-rw-r--r--  2 root supergroup    330326458 2026-03-11 09:42
libros/random_words.txt.bz2
```

0.0.3 Acceso a HDFS desde python con pyarrow

PyArrow proporciona una interfaz Python para interactuar con HDFS a través de su módulo `pyarrow.fs.HadoopFileSystem`. Esto nos permite realizar operaciones sobre HDFS directamente

desde Python sin necesidad de usar comandos de shell.

Preparación del entorno Como usuario root en el contenedor namenode, ejecuta los siguientes pasos:

1. Crear un entorno virtual Python:

```
# Conectarse al contenedor namenode
docker exec -it namenode /bin/bash

# Cambiar al usuario root
# No need to switch user, running as root

# Crear el entorno virtual
python3 -m venv ~/.venv

# Activar el entorno virtual
source ~/.venv/bin/activate
```

2. Instalar PyArrow:

```
# Con el entorno virtual activado
pip install pyarrow
```

3. Configurar las variables de entorno para Hadoop:

```
export CLASSPATH="$(hadoop classpath --glob):$CLASSPATH"
```

4. Verificar la instalación:

```
python3 -c "import pyarrow as pa; print(f'PyArrow version: {pa.__version__}')"

```

```
[16]: # Conectarse al contenedor namenode
!docker exec -it namenode /bin/bash

# Cambiar al usuario root
# No need to switch user, running as root

# Crear el entorno virtual
!python3 -m venv ~/.venv

# Activar el entorno virtual
# source ~/.venv/bin/activate # 'source' no funciona en celdas, usar variables
↪ de entorno Python
```

/bin/bash: line 1: docker: command not found

```
[17]: # Con el entorno virtual activado
!pip install pyarrow
```

WARNING: The directory '/home/jovyan/.cache/pip' or its parent directory is not owned or is not writable by the current user. The cache has been disabled. Check the permissions and owner of that directory. If executing pip with sudo, you should use sudo's -H flag.

Requirement already satisfied: pyarrow in /opt/conda/lib/python3.11/site-packages (23.0.1)

WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager. It is recommended to use a virtual environment instead: <https://pip.pypa.io/warnings/venv>

```
[18]: !export CLASSPATH="$(hadoop classpath --glob):$CLASSPATH"
```

```
[19]: !python3 -c "import pyarrow as pa; print(f'PyArrow version: {pa.__version__}')" 
```

PyArrow version: 23.0.1

Ejemplos de uso del API de PyArrow FileSystem A continuación se muestran ejemplos equivalentes a los comandos `hdfs dfs` vistos anteriormente, pero usando Python y PyArrow:

```
[20]: %pip install -q --upgrade pyarrow
```

WARNING: The directory '/home/jovyan/.cache/pip' or its parent directory is not owned or is not writable by the current user. The cache has been disabled. Check the permissions and owner of that directory. If executing pip with sudo, you should use sudo's -H flag.

WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager. It is recommended to use a virtual environment instead:

<https://pip.pypa.io/warnings/venv>

Note: you may need to restart the kernel to use updated packages.

```
[21]: # Execute hadoop classpath --glob and set CLASSPATH environment variable
import os
import subprocess

classpath = subprocess.check_output(["hadoop", "classpath", "--glob"]).
    .decode("utf-8").strip()
os.environ["CLASSPATH"] = classpath
```

Ejemplo 1: Conectar a HDFS y listar directorios

```
[22]: import pyarrow as pa
from pyarrow import fs
from pyarrow.fs import FileInfo, FileSystem

# Conectar a HDFS (namenode en puerto 9000)
hdfs: FileSystem = fs.HadoopFileSystem(host="namenode", port=9000,
    ↪user="jovyan")

def print_file_list_info(file_info_list: list[FileInfo]):
    for file_info in file_info_list:
        file_type: str | None = file_info.type.name if file_info.type else
    ↪"UNKNOWN"
        file_size: int = file_info.size if file_info.size is not None else 0
        print(f"{file_type:10} {file_size:>10} {file_info.path}")

# Listar contenido del directorio home del usuario
print("=== Contenido del directorio home ===")
file_info_list: list[FileInfo] = hdfs.get_file_info(fs.FileSelector("/user/
    ↪jovyan"))
print_file_list_info(file_info_list)

# Listar el directorio raíz
print("\n=== Contenido del directorio raíz / ===")
root_info: list[FileInfo] = hdfs.get_file_info(fs.FileSelector("/"))
print_file_list_info(root_info)
```

```
=== Contenido del directorio home ===
```

```
=== Contenido del directorio raíz / ===
```

```
Directory          0 /data
```

```
Directory          0 /user
```

Ejemplo 2: Crear directorios

```
[23]: # Crear un directorio simple
hdfs.create_dir("/user/root/datos_python")
print("Directorio 'datos_python' creado")

# Crear estructura de directorios (equivalente a mkdir -p)
hdfs.create_dir("/user/root/datos_python/entrada")
hdfs.create_dir("/user/root/datos_python/procesados/resultados")
print("Estructura de directorios creada")

# Verificar creación
```

```

file_list: list[FileInfo] = hdfs.get_file_info(
    fs.FileSelector("/user/root/datos_python", recursive=True)
)
print("=== Estructura creada ===")
print_file_list_info(file_list)

```

```

Directorio 'datos_python' creado
Estructura de directorios creada
=== Estructura creada ===
Directory      0 /user/root/datos_python/entrada
Directory      0 /user/root/datos_python/procesados
Directory      0 /user/root/datos_python/procesados/resultados

```

Ejemplo 3: Escribir archivos en HDFS

```

[24]: # Escribir un archivo de texto directamente en HDFS
with hdfs.open_output_stream("/user/root/datos_python/entrada/archivo1.txt") as f:
    f.write(b"Este es el contenido del archivo 1 desde Python\n")
    f.write("Segunda línea del archivo\n".encode())

print("Archivo archivo1.txt creado")

# Escribir otro archivo
contenido = "Contenido del archivo número 2 desde PyArrow"
with hdfs.open_output_stream("/user/root/datos_python/entrada/archivo2.txt") as f:
    f.write(contenido.encode("utf-8"))

print("Archivo archivo2.txt creado")

# Copiar un archivo local a HDFS
import os

# Crear archivo local temporal
local_file = "/tmp/archivo_local.txt"
with open(local_file, "w") as f:
    f.write("Contenido desde archivo local\n")

# Copiar a HDFS usando copy_file
with open(local_file, "rb") as local_f:
    with hdfs.open_output_stream("/user/root/datos_python/desde_local.txt") as hdfs_f:
        hdfs_f.write(local_f.read())

print("Archivo copiado desde local a HDFS")

```



```
# Limpiar archivo local
os.remove(local_file)
```

Archivo archivo1.txt creado
Archivo archivo2.txt creado
Archivo copiado desde local a HDFS

Ejemplo 4: Leer archivos de HDFS

```
[25]: # Leer contenido de un archivo (equivalente a hdfs dfs -cat)
with hdfs.open_input_stream("/user/root/datos_python/entrada/archivo1.txt") as f:
    contenido: bytes = f.read()
    print("=== Contenido de archivo1.txt ===")
    print(contenido.decode("utf-8"))

# Leer con readall (más eficiente para archivos completos)
contenido2: bytes = hdfs.open_input_stream(
    "/user/root/datos_python/entrada/archivo2.txt"
).readall()
print("\n=== Contenido de archivo2.txt ===")
print(contenido2.decode("utf-8"))
```

=== Contenido de archivo1.txt ===
Este es el contenido del archivo 1 desde Python
Segunda línea del archivo

=== Contenido de archivo2.txt ===
Contenido del archivo número 2 desde PyArrow

Ejemplo 5: Copiar y mover archivos dentro de HDFS

```
[26]: # Copiar un archivo (PyArrow no tiene copy directo, hay que leer y escribir)

def copy_file_hdfs(hdfs_fs, src, dst):
    """Copia un archivo en HDFS de src a dst"""
    with hdfs_fs.open_input_stream(src) as f_in:
        with hdfs_fs.open_output_stream(dst) as f_out:
            f_out.write(f_in.read())

# Copiar archivo
copy_file_hdfs(
    hdfs,
    "/user/root/datos_python/entrada/archivo1.txt",
    "/user/root/datos_python/copia_archivo1.txt",
```

```

)
print("Archivo copiado")

# Mover archivo (equivalente a hdfs dfs -mv)
hdfs.move(
    "/user/root/datos_python/copia_archivo1.txt",
    "/user/root/datos_python/procesados/archivo_movido.txt",
)
print("Archivo movido")

# Verificar
print_file_list_info(hdfs.get_file_info(fs.FileSelector("/user/root/
↳datos_python/procesados"))))

```

Archivo copiado

Archivo movido

File 75 /user/root/datos_python/procesados/archivo_movido.txt

Directory 0 /user/root/datos_python/procesados/resultados

Ejemplo 6: Obtener información de archivos

```

[27]: from pyarrow.fs import FileInfo

# Información detallada de un archivo específico
file_info: FileInfo = hdfs.get_file_info("/user/root/datos_python/entrada/
↳archivo1.txt")
print("=== Información de archivo ===")
print(f"Ruta: {file_info.path}")
print(f"Tipo: {file_info.type.name}")
print(f"Tamaño: {file_info.size} bytes")
print(f"Tiempo modificación: {file_info.mtime}")

# Tamaño de un directorio (recursivo)
dir_selector = fs.FileSelector("/user/root/datos_python", recursive=True)
total_size = 0
file_count = 0

for info in hdfs.get_file_info(dir_selector):
    if info.type == fs.FileType.File:
        total_size += info.size
        file_count += 1
        print(f"{info.size:>10} bytes {info.path}")

print(f"\nTotal: {file_count} archivos, {total_size} bytes")

```

=== Información de archivo ===

Ruta: /user/root/datos_python/entrada/archivo1.txt

Tipo: File

Tamaño: 75 bytes

Tiempo modificación: 2026-03-11 10:25:42+00:00

30 bytes /user/root/datos_python/desde_local.txt

75 bytes /user/root/datos_python/entrada/archivo1.txt

45 bytes /user/root/datos_python/entrada/archivo2.txt

75 bytes /user/root/datos_python/procesados/archivo_movido.txt

Total: 4 archivos, 225 bytes

Ejemplo 7: Eliminar archivos y directorios

```
[28]: # Eliminar un archivo específico
hdfs.delete_file("/user/root/datos_python/desde_local.txt")
print("Archivo eliminado")

# Eliminar directorio con contenido (equivalente a hdfs dfs -rm -r)
hdfs.delete_dir("/user/root/datos_python/procesados")
print("Directorio 'procesados' eliminado recursivamente")

# Verificar eliminación
remaining: list[FileInfo] = hdfs.get_file_info(
    fs.FileSelector("/user/root/datos_python", recursive=True)
)
print("\n=== Archivos restantes ===")
for info in remaining:
    print(f"{info.type.name:10} {info.path}")
```

Archivo eliminado

Directorio 'procesados' eliminado recursivamente

=== Archivos restantes ===

Directory /user/root/datos_python/entrada

File /user/root/datos_python/entrada/archivo1.txt

File /user/root/datos_python/entrada/archivo2.txt

Ejemplo 8: Trabajar con PyArrow Tables y Parquet PyArrow es especialmente útil para trabajar con datos en formato Parquet directamente en HDFS:

```
[29]: import pandas as pd
import pyarrow.parquet as pq

# Crear un DataFrame de ejemplo
df = pd.DataFrame(
    {
        "id": range(1, 101),
        "nombre": [f"Producto_{i}" for i in range(1, 101)],
        "precio": [10.5 + i * 0.5 for i in range(100)],
        "categoria": ["A", "B", "C", "D"] * 25,
```

```

    }
)

# Convertir a tabla de PyArrow
table: pa.Table = pa.Table.from_pandas(df)

# Escribir como Parquet en HDFS
pq.write_table(table, "/user/root/datos_python/productos.parquet",
    ↪filesystem=hdfs)
print("Archivo Parquet escrito en HDFS")

# Leer el archivo Parquet desde HDFS
tabla_leida: pa.Table = pq.read_table("/user/root/datos_python/productos.
    ↪parquet", filesystem=hdfs)
print("\n=== Tabla leída desde HDFS ===")
print(f"Filas: {tabla_leida.num_rows}, Columnas: {tabla_leida.num_columns}")
print(tabla_leida.schema)

# Convertir de vuelta a pandas
df_leido: pd.DataFrame = tabla_leida.to_pandas()
print("\nPrimeras filas:")
print(df_leido.head())

```

Archivo Parquet escrito en HDFS

```

=== Tabla leída desde HDFS ===
Filas: 100, Columnas: 4
id: int64
nombre: string
precio: double
categoria: string
-- schema metadata --
pandas: '{"index_columns": [{"kind": "range", "name": null, "start": 0, "' + 723

```

Primeras filas:

	id	nombre	precio	categoria
0	1	Producto_1	10.5	A
1	2	Producto_2	11.0	B
2	3	Producto_3	11.5	C
3	4	Producto_4	12.0	D
4	5	Producto_5	12.5	A

Ejemplo 9: Limpieza final

```

[30]: # Eliminar todo el directorio de prueba
hdfs.delete_dir("/user/root/datos_python")
print("Directorio 'datos_python' eliminado completamente")

```

```
# Verificar que el directorio home está limpio
print("=== Contenido final del directorio home ===")
print_file_list_info(hdfs.get_file_info(fs.FileSelector("/user/root")))
```

```
Directorio 'datos_python' eliminado completamente
=== Contenido final del directorio home ===
Directory          0 /user/root/libros
```

Ventajas de usar PyArrow para HDFS

- **Integración nativa:** Conexión directa con HDFS sin necesidad de comandos shell
- **Formato Parquet:** Lectura/escritura eficiente de datos columnares
- **Rendimiento:** Operaciones optimizadas en C++ subyacente
- **Portabilidad:** Mismo código funciona con diferentes sistemas de archivos (HDFS, S3, local)
- **Pythonic:** API orientada a objetos más natural para desarrolladores Python

Notas importantes

- **Conexión HDFS:** Usar `host='namenode'` y `port=9000` (configurado en `core-site.xml`). PyArrow permite también un caso especial con `hdfs://default:0`, para que el código funcione en cualquier entorno Hadoop una vez que PyArrow tiene acceso a la configuración de Hadoop.
- **Usuario:** Especificar `user='root'` para mantener permisos consistentes
- **Rutas:** Siempre usar rutas absolutas (comenzando con `/`)
- **Tipos de archivo:** PyArrow distingue entre `FileType.File`, `FileType.Directory`, y `FileType.NotFound`
- **Encoding:** Recordar codificar/decodificar strings a bytes cuando sea necesario

0.0.4 Acceso con Visual Studio Code al clúster a través de un servidor Jupyter

El contenedor del NameNode/ResourceManager se puede ejecutar un servidor Jupyter que permite acceder al clúster Hadoop a través de una URL de conexión a un servidor Jupyter, y por lo tanto, a través de Visual Studio Code (y también de la web).

Existen varias formas de hacerlo. Por ejemplo, usando la utilidad “DevContainer” de Visual Studio Code, que permite definir un entorno de desarrollo basado en contenedores Docker. Sin embargo, lo haremos manualmente.

A continuación se explica cómo hacerlo.

Lo primero, suponemos que existe un virtual environment de Python para el usuario `root`. Si no es así, créalo y actívalo:

```
python3 -m venv ~/.venv
. ~/.venv/bin/activate
```

Si ya existe, sólo hace falta activarlo:

```
. ~/.venv/bin/activate
```

```
[31]: !python3 -m venv ~/.venv
      !. ~/.venv/bin/activate
```

```
[32]: !. ~/.venv/bin/activate
```

Lo siguiente es instalar los paquetes necesarios:

```
pip install jupyter
```

```
[33]: !pip install jupyter
```

WARNING: The directory '/home/jovyan/.cache/pip' or its parent directory is not owned or is not writable by the current user. The cache has been disabled. Check the permissions and owner of that directory. If executing pip with sudo, you should use sudo's -H flag.

```
Requirement already satisfied: jupyter in /opt/conda/lib/python3.11/site-packages (1.1.1)
Requirement already satisfied: notebook in /opt/conda/lib/python3.11/site-packages (from jupyter) (7.0.6)
Requirement already satisfied: jupyter-console in /opt/conda/lib/python3.11/site-packages (from jupyter) (6.6.3)
Requirement already satisfied: nbconvert in /opt/conda/lib/python3.11/site-packages (from jupyter) (7.9.2)
Requirement already satisfied: ipykernel in /opt/conda/lib/python3.11/site-packages (from jupyter) (6.25.2)
Requirement already satisfied: ipywidgets in /opt/conda/lib/python3.11/site-packages (from jupyter) (8.1.1)
Requirement already satisfied: jupyterlab in /opt/conda/lib/python3.11/site-packages (from jupyter) (4.0.7)
Requirement already satisfied: comm>=0.1.1 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (0.1.4)
Requirement already satisfied: debugpy>=1.6.5 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (1.8.0)
Requirement already satisfied: ipython>=7.23.1 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (8.16.1)
Requirement already satisfied: jupyter-client>=6.1.12 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (8.4.0)
Requirement already satisfied: jupyter-core!=5.0.*,>=4.12 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (5.4.0)
Requirement already satisfied: matplotlib-inline>=0.1 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (0.1.6)
Requirement already satisfied: nest-asyncio in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (1.5.8)
Requirement already satisfied: packaging in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (23.2)
Requirement already satisfied: psutil in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (5.9.5)
Requirement already satisfied: pyzmq>=20 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (25.1.1)
```

Requirement already satisfied: tornado>=6.1 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (6.3.3)
Requirement already satisfied: traitlets>=5.4.0 in /opt/conda/lib/python3.11/site-packages (from ipykernel->jupyter) (5.11.2)
Requirement already satisfied: widgetsnbextension~=4.0.9 in /opt/conda/lib/python3.11/site-packages (from ipywidgets->jupyter) (4.0.9)
Requirement already satisfied: jupyterlab-widgets~=3.0.9 in /opt/conda/lib/python3.11/site-packages (from ipywidgets->jupyter) (3.0.9)
Requirement already satisfied: prompt-toolkit>=3.0.30 in /opt/conda/lib/python3.11/site-packages (from jupyter-console->jupyter) (3.0.39)
Requirement already satisfied: pygments in /opt/conda/lib/python3.11/site-packages (from jupyter-console->jupyter) (2.16.1)
Requirement already satisfied: async-lru>=1.0.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (2.0.4)
Requirement already satisfied: Jinja2>=3.0.3 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (3.1.2)
Requirement already satisfied: jupyter-lsp>=2.0.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (2.2.0)
Requirement already satisfied: jupyter-server<3,>=2.4.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (2.8.0)
Requirement already satisfied: jupyterlab-server<3,>=2.19.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (2.25.0)
Requirement already satisfied: notebook-shim>=0.2 in /opt/conda/lib/python3.11/site-packages (from jupyterlab->jupyter) (0.2.3)
Requirement already satisfied: beautifulsoup4 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (4.12.2)
Requirement already satisfied: bleach!=5.0.0 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (6.1.0)
Requirement already satisfied: defusedxml in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (0.7.1)
Requirement already satisfied: jupyterlab-pygments in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (0.2.2)
Requirement already satisfied: markupsafe>=2.0 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (2.1.3)
Requirement already satisfied: mistune<4,>=2.0.3 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (3.0.1)
Requirement already satisfied: nbclient>=0.5.0 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (0.8.0)
Requirement already satisfied: nbformat>=5.7 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (5.9.2)
Requirement already satisfied: pandocfilters>=1.4.1 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (1.5.0)
Requirement already satisfied: tinycss2 in /opt/conda/lib/python3.11/site-packages (from nbconvert->jupyter) (1.2.1)
Requirement already satisfied: six>=1.9.0 in /opt/conda/lib/python3.11/site-packages (from bleach!=5.0.0->nbconvert->jupyter) (1.16.0)
Requirement already satisfied: webencodings in /opt/conda/lib/python3.11/site-packages (from bleach!=5.0.0->nbconvert->jupyter) (0.5.1)

Requirement already satisfied: backcall in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (0.2.0)

Requirement already satisfied: decorator in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (5.1.1)

Requirement already satisfied: jedi>=0.16 in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (0.19.1)

Requirement already satisfied: pickleshare in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (0.7.5)

Requirement already satisfied: stack-data in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (0.6.2)

Requirement already satisfied: pexpect>4.3 in /opt/conda/lib/python3.11/site-packages (from ipython>=7.23.1->ipykernel->jupyter) (4.8.0)

Requirement already satisfied: python-dateutil>=2.8.2 in /opt/conda/lib/python3.11/site-packages (from jupyter-client>=6.1.12->ipykernel->jupyter) (2.8.2)

Requirement already satisfied: platformdirs>=2.5 in /opt/conda/lib/python3.11/site-packages (from jupyter-core!=5.0.*,>=4.12->ipykernel->jupyter) (3.11.0)

Requirement already satisfied: anyio>=3.1.0 in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (4.0.0)

Requirement already satisfied: argon2-cffi in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (23.1.0)

Requirement already satisfied: jupyter-events>=0.6.0 in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.8.0)

Requirement already satisfied: jupyter-server-terminals in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.4.4)

Requirement already satisfied: overrides in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (7.4.0)

Requirement already satisfied: prometheus-client in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.17.1)

Requirement already satisfied: send2trash>=1.8.2 in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.8.2)

Requirement already satisfied: terminado>=0.8.3 in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.17.1)

Requirement already satisfied: websocket-client in /opt/conda/lib/python3.11/site-packages (from jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.6.4)

Requirement already satisfied: babel>=2.10 in /opt/conda/lib/python3.11/site-packages (from jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (2.13.0)

Requirement already satisfied: json5>=0.9.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (0.9.14)

Requirement already satisfied: jsonschema>=4.18.0 in /opt/conda/lib/python3.11/site-packages (from jupyterlab-

server<3,>=2.19.0->jupyterlab->jupyter) (4.19.1)
Requirement already satisfied: requests>=2.31 in /opt/conda/lib/python3.11/site-packages (from jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (2.31.0)
Requirement already satisfied: fastjsonschema in /opt/conda/lib/python3.11/site-packages (from nbformat>=5.7->nbconvert->jupyter) (2.18.1)
Requirement already satisfied: wcwidth in /opt/conda/lib/python3.11/site-packages (from prompt-toolkit>=3.0.30->jupyter-console->jupyter) (0.2.8)
Requirement already satisfied: soupsieve>1.2 in /opt/conda/lib/python3.11/site-packages (from beautifulsoup4->nbconvert->jupyter) (2.5)
Requirement already satisfied: idna>=2.8 in /opt/conda/lib/python3.11/site-packages (from anyio>=3.1.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (3.4)
Requirement already satisfied: sniffio>=1.1 in /opt/conda/lib/python3.11/site-packages (from anyio>=3.1.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.3.0)
Requirement already satisfied: parso<0.9.0,>=0.8.3 in /opt/conda/lib/python3.11/site-packages (from jedi>=0.16->ipython>=7.23.1->ipykernel->jupyter) (0.8.3)
Requirement already satisfied: attrs>=22.2.0 in /opt/conda/lib/python3.11/site-packages (from jsonschema>=4.18.0->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (23.1.0)
Requirement already satisfied: jsonschema-specifications>=2023.03.6 in /opt/conda/lib/python3.11/site-packages (from jsonschema>=4.18.0->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (2023.7.1)
Requirement already satisfied: referencing>=0.28.4 in /opt/conda/lib/python3.11/site-packages (from jsonschema>=4.18.0->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (0.30.2)
Requirement already satisfied: rpds-py>=0.7.1 in /opt/conda/lib/python3.11/site-packages (from jsonschema>=4.18.0->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (0.10.6)
Requirement already satisfied: python-json-logger>=2.0.4 in /opt/conda/lib/python3.11/site-packages (from jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (2.0.7)
Requirement already satisfied: pyyaml>=5.3 in /opt/conda/lib/python3.11/site-packages (from jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (6.0.1)
Requirement already satisfied: rfc3339-validator in /opt/conda/lib/python3.11/site-packages (from jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.1.4)
Requirement already satisfied: rfc3986-validator>=0.1.1 in /opt/conda/lib/python3.11/site-packages (from jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (0.1.1)
Requirement already satisfied: ptyprocess>=0.5 in /opt/conda/lib/python3.11/site-packages (from pexpect>4.3->ipython>=7.23.1->ipykernel->jupyter) (0.7.0)
Requirement already satisfied: charset-normalizer<4,>=2 in /opt/conda/lib/python3.11/site-packages (from requests>=2.31->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (3.3.0)

Requirement already satisfied: urllib3<3,>=1.21.1 in /opt/conda/lib/python3.11/site-packages (from requests>=2.31->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (2.0.7)

Requirement already satisfied: certifi>=2017.4.17 in /opt/conda/lib/python3.11/site-packages (from requests>=2.31->jupyterlab-server<3,>=2.19.0->jupyterlab->jupyter) (2023.7.22)

Requirement already satisfied: argon2-cffi-bindings in /opt/conda/lib/python3.11/site-packages (from argon2-cffi->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (21.2.0)

Requirement already satisfied: executing>=1.2.0 in /opt/conda/lib/python3.11/site-packages (from stack-data->ipython>=7.23.1->ipykernel->jupyter) (1.2.0)

Requirement already satisfied: asttokens>=2.1.0 in /opt/conda/lib/python3.11/site-packages (from stack-data->ipython>=7.23.1->ipykernel->jupyter) (2.4.0)

Requirement already satisfied: pure-eval in /opt/conda/lib/python3.11/site-packages (from stack-data->ipython>=7.23.1->ipykernel->jupyter) (0.2.2)

Requirement already satisfied: fqdn in /opt/conda/lib/python3.11/site-packages (from jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.5.1)

Requirement already satisfied: isoduration in /opt/conda/lib/python3.11/site-packages (from jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (20.11.0)

Requirement already satisfied: jsonpointer>1.13 in /opt/conda/lib/python3.11/site-packages (from jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (2.4)

Requirement already satisfied: uri-template in /opt/conda/lib/python3.11/site-packages (from jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.3.0)

Requirement already satisfied: webcolors>=1.11 in /opt/conda/lib/python3.11/site-packages (from jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.13)

Requirement already satisfied: cffi>=1.0.1 in /opt/conda/lib/python3.11/site-packages (from argon2-cffi-bindings->argon2-cffi->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.16.0)

Requirement already satisfied: pycparser in /opt/conda/lib/python3.11/site-packages (from cffi>=1.0.1->argon2-cffi-bindings->argon2-cffi->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (2.21)

Requirement already satisfied: arrow>=0.15.0 in /opt/conda/lib/python3.11/site-packages (from isoduration->jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (1.3.0)

Requirement already satisfied: types-python-dateutil>=2.8.10 in /opt/conda/lib/python3.11/site-packages (from arrow>=0.15.0->isoduration->jsonschema[format-nongpl]>=4.18.0->jupyter-events>=0.6.0->jupyter-server<3,>=2.4.0->jupyterlab->jupyter) (2.8.19.14)

WARNING: Running pip as the 'root' user can result in broken permissions and conflicting behaviour with the system package manager. It is recommended to use a virtual environment instead: <https://pip.pypa.io/warnings/venv>

[]:

Una vez instalado Jupyter, lanza el servidor Jupyter con el siguiente comando (como usuario root):

```
jupyter notebook --ip=0.0.0.0 --no-browser --allow-root --NotebookApp.token='bigdata' --NotebookApp.password=''
```

```
[34]: !jupyter notebook --ip=0.0.0.0 --no-browser --allow-root --NotebookApp.  
      ↪token='bigdata' --NotebookApp.password=''
```

```
[I 2026-03-11 10:26:06.666 ServerApp] Package notebook took 0.0000s to  
import  
[I 2026-03-11 10:26:06.693 ServerApp] Package jupyter_lsp took 0.0252s  
to import  
[W 2026-03-11 10:26:06.693 ServerApp] A  
`_jupyter_server_extension_points` function was not found in jupyter_lsp.  
Instead, a `_jupyter_server_extension_paths` function was found and will be used  
for now. This function name will be deprecated in future releases of Jupyter  
Server.  
[I 2026-03-11 10:26:06.696 ServerApp] Package jupyter_server_mathjax  
took 0.0023s to import  
[I 2026-03-11 10:26:06.703 ServerApp] Package jupyter_server_terminals  
took 0.0064s to import  
[I 2026-03-11 10:26:06.703 ServerApp] Package jupyterlab took 0.0000s to  
import  
[I 2026-03-11 10:26:07.555 ServerApp] Package jupyterlab_git took  
0.0443s to import  
[I 2026-03-11 10:26:07.558 ServerApp] Package nbclassic took 0.0026s to  
import  
[W 2026-03-11 10:26:07.561 ServerApp] A  
`_jupyter_server_extension_points` function was not found in nbclassic. Instead,  
a `_jupyter_server_extension_paths` function was found and will be used for now.  
This function name will be deprecated in future releases of Jupyter Server.  
[I 2026-03-11 10:26:07.562 ServerApp] Package nbdtm took 0.0000s to  
import  
[I 2026-03-11 10:26:07.562 ServerApp] Package notebook_shim took 0.0000s  
to import  
[W 2026-03-11 10:26:07.562 ServerApp] A  
`_jupyter_server_extension_points` function was not found in notebook_shim.  
Instead, a `_jupyter_server_extension_paths` function was found and will be used  
for now. This function name will be deprecated in future releases of Jupyter  
Server.  
[I 2026-03-11 10:26:07.563 ServerApp] jupyter_lsp | extension was
```

```

successfully linked.
[I 2026-03-11 10:26:07.569 ServerApp] jupyter_server_mathjax | extension
was successfully linked.
[I 2026-03-11 10:26:07.575 ServerApp] jupyter_server_terminals |
extension was successfully linked.
[W 2026-03-11 10:26:07.577 LabApp] 'token' has moved from NotebookApp to
ServerApp. This config will be passed to ServerApp. Be sure to update your
config before our next release.
[W 2026-03-11 10:26:07.577 LabApp] 'password' has moved from NotebookApp
to ServerApp. This config will be passed to ServerApp. Be sure to update your
config before our next release.
[W 2026-03-11 10:26:07.583 ServerApp] ServerApp.token config is
deprecated in 2.0. Use IdentityProvider.token.
[I 2026-03-11 10:26:07.583 ServerApp] jupyterlab | extension was
successfully linked.
[I 2026-03-11 10:26:07.583 ServerApp] jupyterlab_git | extension was
successfully linked.
[I 2026-03-11 10:26:07.592 ServerApp] nbclassic | extension was
successfully linked.
[I 2026-03-11 10:26:07.593 ServerApp] nbdime | extension was
successfully linked.
[I 2026-03-11 10:26:07.601 ServerApp] notebook | extension was
successfully linked.
[I 2026-03-11 10:26:07.921 ServerApp] notebook_shim | extension was
successfully linked.
[I 2026-03-11 10:26:07.983 ServerApp] notebook_shim | extension was
successfully loaded.
[I 2026-03-11 10:26:07.989 ServerApp] jupyter_lsp | extension was
successfully loaded.
[I 2026-03-11 10:26:07.991 ServerApp] jupyter_server_mathjax | extension
was successfully loaded.
[I 2026-03-11 10:26:07.992 ServerApp] jupyter_server_terminals |
extension was successfully loaded.
[I 2026-03-11 10:26:07.994 LabApp] JupyterLab extension loaded from
/opt/conda/lib/python3.11/site-packages/jupyterlab
[I 2026-03-11 10:26:07.994 LabApp] JupyterLab application directory is
/opt/conda/share/jupyter/lab
[I 2026-03-11 10:26:07.994 LabApp] Extension Manager is 'pypi'.
[I 2026-03-11 10:26:07.997 ServerApp] jupyterlab | extension was
successfully loaded.
[I 2026-03-11 10:26:08.001 ServerApp] jupyterlab_git | extension was
successfully loaded.

```

```

_ _ _ _ _
| | | | _ _ _ _ | | _ _ _
| | | | ' \ / ' / _ _ | _ / - )
\ _ _ / | . _ _ \ _ _ , \ _ _ \ _ _ \ _ _ \ _ _ \ _ _
| |

```

Read the migration plan to Notebook 7 to learn about the new features and the actions to take if you are using extensions.

https://jupyter-notebook.readthedocs.io/en/latest/migrate_to_notebook7.html

Please note that updating to Notebook 7 might break some of your extensions.

```
[I 2026-03-11 10:26:08.006 ServerApp] nbclassic | extension was
successfully loaded.
[I 2026-03-11 10:26:08.066 ServerApp] nbdime | extension was
successfully loaded.
[I 2026-03-11 10:26:08.073 ServerApp] notebook | extension was
successfully loaded.
[I 2026-03-11 10:26:08.074 ServerApp] The port 8888 is already in use,
trying another port.
[I 2026-03-11 10:26:08.075 ServerApp] Serving notebooks from local
directory: /tmp
[I 2026-03-11 10:26:08.075 ServerApp] Jupyter Server 2.8.0 is running
at:
[I 2026-03-11 10:26:08.075 ServerApp]
http://f3b61ef67c45:8889/tree?token=...
[I 2026-03-11 10:26:08.075 ServerApp]
http://127.0.0.1:8889/tree?token=...
[I 2026-03-11 10:26:08.075 ServerApp] Use Control-C to stop this server
and shut down all kernels (twice to skip confirmation).
[I 2026-03-11 10:26:09.027 ServerApp] Skipped non-installed server(s):
bash-language-server, dockerfile-language-server-nodejs, javascript-typescript-
langserver, jedi-language-server, julia-language-server, pyright, python-
language-server, python-lsp-server, r-languageserver, sql-language-server,
texlab, typescript-language-server, unified-language-server, vscode-css-
languageserver-bin, vscode-html-languageserver-bin, vscode-json-languageserver-
bin, yaml-language-server
^C
[I 2026-03-11 10:28:03.650 ServerApp] interrupted
[I 2026-03-11 10:28:03.651 ServerApp] Serving notebooks from local
directory: /tmp
    0 active kernels
    Jupyter Server 2.8.0 is running at:
    http://f3b61ef67c45:8889/tree?token=...
    http://127.0.0.1:8889/tree?token=...
Shutdown this Jupyter server (y/[n])? [I 2026-03-11 10:28:03.651
ServerApp] resuming operation...
```

Con esto, el servidor Jupyter quedará escuchando en el puerto 8888 del contenedor del NameNode, que a su vez tiene mapeado el puerto al exterior, así que se podrá acceder desde el navegador web o desde Visual Studio Code.

En Visual Studio Code, hay que seleccionar el kernel:

Después, “Select Another Kernel...” y en la ventana que aparece, seleccionar “Existing Jupyter Server”:

Con la URL `http://localhost:8888/?token=bigdata`.

A partir de ahí, todos los *Notebooks* locales se ejecutarán en el contenedor del NameNode, con acceso al clúster Hadoop.

`http://localhost:8888/?token=bigdata`