

01_Introduccion_Hadoop

March 11, 2026

1 1. Introducción al Cluster Hadoop

Bienvenido a tu entorno de Big Data. Este notebook te guiará por los componentes principales que ya tienes funcionando.

1.1 ¿Qué es Hadoop?

Apache Hadoop es un framework que permite procesar grandes conjuntos de datos utilizando modelos de programación simples en clusters de ordenadores. Está diseñado para escalar desde un único servidor hasta miles de máquinas.

El núcleo de Hadoop consta de dos partes principales:

1.1.1 1. HDFS (Hadoop Distributed File System)

Es el sistema de almacenamiento. Imagínalo como un disco duro gigante repartido entre todos los ordenadores del cluster.

- **NameNode (Maestro):** Es el bibliotecario. Sabe dónde está cada archivo, pero no guarda los datos reales. Si se cae, perdemos el acceso a todo (por eso es crítico).
- **DataNodes (Esclavos):** Son los almacenes. Guardan los bloques de datos reales. En nuestro cluster tenemos **2 DataNodes**.

1.1.2 2. YARN (Yet Another Resource Negotiator)

Es el sistema operativo del cluster. Gestiona quién usa la CPU y la RAM.

- **ResourceManager:** El jefe. Decide cuántos recursos le da a cada tarea.
- **NodeManager:** El empleado. Vigila los recursos en cada máquina y reporta al jefe.

1.2 1.1 Configuración: Los Archivos XML

Hadoop se configura mediante archivos XML. En este entorno, los encontrarás en la carpeta **config/** del proyecto. Aquí tienes una explicación rápida de qué hace cada uno para que entiendas la “magia” que ocurre por debajo:

1.2.1 1. core-site.xml (El Núcleo)

Define el sistema de archivos por defecto. - **Propiedad Clave:** `fs.defaultFS = hdfs://namenode:9000` - **¿Qué significa?:** Le dice a todos los servicios que el “jefe” del sistema de archivos (NameNode) vive en el contenedor `namenode` y escucha en el puerto 9000.

1.2.2 2. hdfs-site.xml (Almacenamiento)

Configura cómo se guardan los datos. - **dfs.replication = 2:** Cada bloque de datos se guarda en 2 sitios distintos (tenemos 2 DataNodes). Si uno falla, el dato sigue vivo en el otro. - **dfs.permissions.enabled = false:** Desactiva la comprobación estricta de permisos para facilitar el aprendizaje en este laboratorio.

1.2.3 3. yarn-site.xml (Recursos)

Configura el sistema operativo del cluster. - **yarn.resourcemanager.hostname = resourcemanager:** Indica quién reparte la CPU y RAM. - **yarn.nodemanager.resource.memory-mb = 1024:** Limita a cada nodo a usar máximo 1GB de RAM para tareas. Esto es clave para que el cluster corra en tu portátil sin colapsarlo. - **yarn.scheduler.minimum-allocation-mb = 256:** Define el tamaño mínimo de un contenedor. Importante para que tareas pequeñas no desperdicien RAM.

1.2.4 4. mapred-site.xml (Cómputo)

Define cómo se procesan los datos. - **mapreduce.framework.name = yarn:** Le dice a Hadoop que use YARN para gestionar las tareas de MapReduce, en lugar del modo antiguo.

1.3 Verificación del Estado del Cluster

Vamos a usar comandos de consola (empezando con `!`) para preguntar al cluster cómo está.

```
[1]: # 1. Preguntar a HDFS por el estado de los DataNodes
!hdfs dfsadmin -report
```

```
Configured Capacity: 2162202353664 (1.97 TB)
Present Capacity: 1924203642880 (1.75 TB)
DFS Remaining: 1882580418560 (1.71 TB)
DFS Used: 41623224320 (38.76 GB)
DFS Used%: 2.16%
Replicated Blocks:
    Under replicated blocks: 0
    Blocks with corrupt replicas: 0
    Missing blocks: 0
    Missing blocks (with replication factor 1): 0
    Low redundancy blocks with highest priority to recover: 0
    Pending deletion blocks: 0
Erasure Coded Block Groups:
    Low redundancy block groups: 0
    Block groups with corrupt internal blocks: 0
    Missing block groups: 0
```

Low redundancy blocks with highest priority to recover: 0
Pending deletion blocks: 0

Live datanodes (2):

Name: 172.18.0.6:9866 (datanode1.hadoop-lab_v4-copia_default)
Hostname: d6cf44cca029
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 20811632640 (19.38 GB)
Non DFS Used: 64007012352 (59.61 GB)
DFS Remaining: 941290176512 (876.64 GB)
DFS Used%: 1.93%
DFS Remaining%: 87.07%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 0
Last contact: Wed Mar 11 16:18:27 UTC 2026
Last Block Report: Wed Mar 11 16:14:33 UTC 2026
Num of Blocks: 289

Name: 172.18.0.7:9866 (datanode2.hadoop-lab_v4-copia_default)
Hostname: 64ba33ef52c1
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 20811591680 (19.38 GB)
Non DFS Used: 64007053312 (59.61 GB)
DFS Remaining: 941290176512 (876.64 GB)
DFS Used%: 1.93%
DFS Remaining%: 87.07%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 0
Last contact: Wed Mar 11 16:18:27 UTC 2026
Last Block Report: Wed Mar 11 11:51:13 UTC 2026
Num of Blocks: 289

Deberías ver **Live datanodes (2)** en el reporte anterior. Eso significa que tus dos almacenes están

operativos.

```
[2]: # 2. Crear una carpeta de usuario en HDFS
# A diferencia de tu disco local, en HDFS tienes que crear explícitamente las
↳ carpetas de usuario.
```

```
!hdfs dfs -mkdir -p /user/hadoop/prueba
!hdfs dfs -ls /user/hadoop
```

Found 1 items

```
drwxr-xr-x  - root supergroup          0 2026-03-11 09:17 /user/hadoop/prueba
```

```
[3]: # 3. Preguntar a YARN qué nodos están activos para procesar tareas
!yarn node -list
```

2026-03-11 16:18:33,675 INFO client.DefaultNoHARMFailoverProxyProvider:

Connecting to ResourceManager at resourcemanager/172.18.0.2:8032

Total Nodes:1

Node-Id	Node-State	Node-Http-Address	Number-of-
Running-Containers			
3622e41b007e:34417	RUNNING	3622e41b007e:8042	
0			

1.4 ¡Todo listo!

Si has ejecutado las celdas sin error, tu cluster está perfecto. En el próximo laboratorio aprenderemos a subir archivos y ejecutar un MapReduce.